Coleta, Preparação e Análise de Dados
Profª Katherine Bianchini Esper de Vargas
Projeto Extensionista

Análise de Dados de Enchentes do INCT SiMAI

Em maio de 2024, o Guaíba chegou a 5,35 m em Porto Alegre, a maior marca da história (Jornal do Comércio). Para entender o que acontece com a cidade em cenários como esse, o INCT SiMAI simulou quais prédios de cada bairro ficam alagados conforme o nível do rio sobe de 3,0 m a 10,0 m.

A ferramenta atual: Hoje o INCT mostra o resultado dessa simulação nesta página: Flood - INCT SiMAI. Ela roda em um servidor próprio, porém sofre de instabilidade e lentidão, o que dificulta que a informação chegue a quem precisa dela, como a defesa civil, a imprensa e os moradores.

Antes de começar, cada equipe deve explorar a ferramenta atual e anotar o que funciona e o que atrapalha: o que é difícil de encontrar, o que demora, o que não fica claro. Essas observações são o ponto de partida do dashboard de vocês e devem aparecer no relatório do dashboard.

O desafio é propor uma alternativa melhor, que responda rapidamente a duas perguntas:

1. **Tela 1:** se o rio chegar a X metros, quais bairros e quantas pessoas são afetados?
2. **Tela 2:** o que outras bases de dados sobre enchentes no Rio Grande do Sul acrescentam a essa resposta?

O trabalho é em equipes de 3 a 5 alunos e percorre o ciclo da disciplina: coleta, preparação, limpeza, análise exploratória (EDA) e comunicação dos resultados. Por ser um projeto extensionista, o produto final é entregue ao parceiro e pode ser usado por ele.

Dashboard: 2 telas

A Tela 1 tem requisitos fixos, iguais para todas as equipes; a Tela 2 é livre, mas precisa usar as bases que a equipe levantou e conversar com a Tela 1.

Tela 1 - Simulação do INCT

Use apenas o JSON fornecido pelo INCT, depois de limpo. A tela deve ter:

- Um controle deslizante do nível do Guaíba, de 3,0 m a 10,0 m em passos de 0,1 m, que atualiza todos os elementos da tela.
- Indicadores no topo: pessoas afetadas, prédios afetados e bairros atingidos no nível escolhido.

- Um gráfico com a porcentagem de prédios afetados em cada bairro atingido. Um mapa dos bairros colorido por essa porcentagem é opcional e conta como diferencial na avaliação do dashboard.
- Uma curva da população afetada em toda a cidade por nível do rio, com o nível recorde de maio de 2024 (5,35 m) marcado.
- Um ranking dos bairros mais afetados no nível escolhido.
- Um aviso visível das limitações dos dados (ver a seção "Os dados do INCT").

Tela 2 - Bases levantadas pela equipe

Use as bases sobre enchentes no RS que a equipe encontrou na Fase 1. O conteúdo é escolha da equipe, mas a tela deve cumprir os requisitos mínimos abaixo.

1. Usar pelo menos uma base externa obtida por código: API, web scraping ou download automatizado.
2. Ter pelo menos 3 visualizações e pelo menos 1 filtro interativo.
3. Ter pelo menos uma visualização que relacione a base externa à Tela 1: pelos bairros, pelo nível do Guaíba ou pela enchente de 2024.
4. Mostrar a fonte de cada dado, com link, e a data de coleta.

Exemplos do que a Tela 2 pode responder:

- Os bairros mais expostos na simulação são os de menor renda?
- Quantas escolas, unidades de saúde ou abrigos ficam em área alagada a cada nível?
- A simulação a 5,3 m bate com a mancha observada em maio de 2024?
- Como o nível do Guaíba se comportou ao longo dos anos e com que frequência passou da cota de inundação?
- Quais municípios do RS tiveram mais pessoas desalojadas ou mais danos em 2024?

Os dados do INCT

O arquivo `data.json` traz, para cada nível do Guaíba de 3,0 m a 10,0 m (71 níveis, em passos de 0,1 m), os 94 bairros de Porto Alegre com 5 campos. A simulação começa em 3,0 m porque, abaixo disso, a cidade não era afetada.

```
{
  "3_0m": {
    "Aberta dos Morros": {
```

```
      "affected_buildings": 0,
      "total_buildings": 4696,
      "percentage": 0,
      "population": 9854,
      "affected_population": 0
    },
    ...
  },
  "3_1m": { ... }
}
```

Campo	Significado	Origem
total_buildings	Total de prédios no bairro	OpenStreetMap
affected_buildings	Prédios atingidos pela água naquele nível	Simulação do INCT
percentage	Porcentagem de prédios afetados	Calculada a partir dos dois campos acima
population	População do bairro	Censo IBGE 2022
affected_population	População afetada estimada	population × percentage / 100

Atenção: o arquivo contém inconsistências reais, que não estão listadas aqui de propósito. Encontrá-las faz parte do trabalho. Para cada uma, a equipe deve:

1. Mostrar onde ela aparece (bairro, nível, valores).
2. Explicar por que é um problema.
3. Decidir como tratar (corrigir, interpolar, descartar ou manter e avisar) e justificar a decisão.

Registre tudo o que for encontrado e corrigido no relatório. As inconsistências encontradas pelas equipes serão enviadas ao INCT como devolutiva.

Dicas para começar:

1. Pense no que deveria acontecer com os prédios afetados de um bairro quando o rio sobe, e teste isso.
2. Confira se os cálculos de `percentage` e `affected_population` estão coerentes com os outros campos.

3. Não assuma que todos os níveis têm a mesma estrutura, os mesmos bairros ou a mesma ordem.
4. A população afetada é uma estimativa: ela supõe que as pessoas se distribuem igualmente entre todos os prédios, inclusive os não residenciais.

Código mínimo para carregar o arquivo em formato longo (uma linha por nível e bairro):

```
import json
import pandas as pd

with open("data.json", encoding="utf-8") as f:
    raw = json.load(f)

df = pd.DataFrame([
    {"nivel_m": float(nivel.removesuffix("m").replace("_", ".")),
     "bairro": bairro, **valores}
    for nivel, bairros in raw.items()
    for bairro, valores in bairros.items()
])
print(df.shape)  # deve dar (6674, 7)
```

Etapas e entregas

O projeto tem 3 fases, cada uma apresentada na aula de acompanhamento, mais a versão final e a apresentação ao INCT. Cada fase é apresentada para a professora na própria aula.

Etapa	Data	O que a equipe entrega e mostra	Pontos
Fase 1 - Levantamento de bases	28/10 (qua)	Relatório relatorios/base_dados.pdf descrevendo as bases sobre enchentes no RS encontradas: origem, conteúdo, recorte espacial e temporal, formato, forma de coleta, licença e como cada uma se liga aos dados do INCT; escolha justificada das bases para a Tela 2 e da pergunta que ela vai responder; repositório criado com README e membros da equipe	10
Fase 2 - Dados limpos e EDA	09/11 (seg)	Scripts de coleta das bases externas; JSON do INCT em formato longo e limpo; relatorios/limpeza_dados.pdf; notebook de EDA com 6 a 10 gráficos comentados (Tela 1 e Tela 2); esboço (wireframe) das duas telas	20
Fase 3 - Protótipo	16/11 (seg)	Dashboard em desenvolvimento, ainda que sem acabamento; relatório	20

Etapa	Data	O que a equipe entrega e mostra	Pontos
		relatorios/dashboard.pdf com o objetivo de cada tela, as visualizações escolhidas e por quê, como usar e as limitações.	
Versão final	24/11 (ter), 23h59	Dashboard final publicado; relatório relatorios/dashboard.pdf atualizado com o que mudou desde a Fase 3.	20
Apresentação	25/11 (qua) ou 30/11 (seg)	Pitch de 10 min com demonstração ao vivo.	30

Requisitos técnicos

Todo o processamento é em Python e precisa ser reprodutível: qualquer pessoa clona o repositório, segue o README e chega ao mesmo dashboard.

- **Linguagem:** Python. Bibliotecas sugeridas: pandas, geopandas, requests, plotly.
- **Dashboard:** Ferramentas vistas em aula.
- **Publicação:** o dashboard deve estar acessível por um link público, por exemplo no Streamlit Community Cloud ou no Hugging Face Spaces (ambos gratuitos).
- **Versionamento:** repositório no GitHub com a professora como colaboradora. Todos os membros devem ter commits.
- **Malha de bairros (só para quem fizer o mapa opcional):** use os limites oficiais dos bairros publicados pela Prefeitura no ObservaPOA. Atenção à grafia dos nomes: acentos e apóstrofos mudam entre fontes.
- **Coleta responsável:** respeite o `robots.txt` e os termos de uso dos sites; guarde os dados brutos localmente para não repetir requisições.

Estrutura sugerida do repositório:

```
projeto-enchentes/
├── README.md              # equipe, link do dashboard, como rodar
├── requirements.txt
├── dados/
│   ├── originais/         # dados como vieram (ou instruções de download, se forem grandes)
│   └── processados/       # dados limpos usados pelo dashboard
├── scripts/               # scripts de coleta e limpeza
```

```
├── notebooks/           # EDA
├── relatorios/
│   ├── base_dados.pdf
│   ├── limpeza_dados.pdf
│   └── dashboard.pdf
└── app/                 # código do dashboard
```

Avaliação

A nota é construída ao longo do projeto: 50 dos 100 pontos vêm das 3 fases, então deixar tudo para a última semana não é suficiente para passar.

1. **Cada fase destrava a seguinte.** Uma fase não entregue vale zero e deve ser entregue junto com a próxima; sem ela, a próxima não é corrigida.
2. **Entrega até o início da aula.** A equipe que não tiver nada para mostrar na conversa da aula pode entregar em até 48 h, perdendo 30% da nota da fase; depois disso, zero.
3. **Presença no acompanhamento.** As Fases 1, 2 e 3 são avaliadas em aula, em conversa com cada grupo. O aluno ausente na aula de acompanhamento tem desconto na sua nota individual daquela fase, mesmo que o grupo tenha entregado.
4. **Registro no fórum do Moodle.** A cada fase, o grupo registra no fórum o que cada aluno fez e em que trabalhou, até o início da aula de acompanhamento. O aluno sem contribuição registrada naquela fase tem desconto na sua nota individual.
5. **Segunda chance para os dados:** as Fases 1 e 2 podem ser reentregues uma vez até 24/11, valendo no máximo 80% dos pontos.
6. **Prazo da versão final:** a professora avalia o repositório considerando os commits feitos até 24/11, às 23h59. Commits feitos em até 48 h depois disso valem com desconto de 30% na nota da versão final; depois de 48 h, não são considerados. O desconto conta a partir da data final de entrega (24/11, às 23h59) e vale para qualquer commit feito depois dela, inclusive depois da apresentação.
7. **Nota individual** = nota da equipe × fator de participação de 0,5 a 1,0, definido pela presença nos acompanhamentos, pelos registros no fórum do Moodle, pelo histórico de commits e pela avaliação entre pares após a apresentação.

Cuidados éticos

O tema é sensível: muitas pessoas em Porto Alegre perderam casa, trabalho ou familiares na enchente de 2024, e algumas podem estar na turma.

- Deixe claro no dashboard que os números são **estimativas de uma simulação**, não previsões nem contagens oficiais.
- Evite linguagem e cores sensacionalistas; o objetivo é informar, não assustar.
- Não publique dados pessoais (nomes, endereços, fotos de pessoas) coletados em redes sociais ou notícias.
- Cite a fonte de todo dado e de todo trecho de código reaproveitado. O uso de ferramentas de IA é permitido, desde que a equipe consiga explicar cada parte do código na conversa de acompanhamento e registre todos os momentos em que a ferramenta foi utilizada. A omissão dessa informação poderá gerar desconto de nota.